

ĐẠI HỌC QUỐC GIA HÀ NỘI

Trường Đại học Công nghệ

Viện Trí tuệ Nhân tạo

Phát hiện Văn bản do AI Sinh ra

AI-Generated Text Detection

Phân loại văn bản Human-written / AI-generated
trên dữ liệu song ngữ Anh-Việt

Nhóm 11 — Thành viên

Nguyễn Đức Minh 24022404

Nguyễn Hoàng Phúc 23021661

Giảng viên hướng dẫn

TS. Nguyễn Thị Thùy Linh

PGS.TS. Nguyễn Việt Hà

Viện Trí tuệ Nhân tạo

Trường Đại học Công nghệ,

DHQGHN

Năm học 2024–2025

Báo cáo Assignment 3 — Môn Học Máy / Xử lý Ngôn ngữ Tự nhiên

Phân công Công việc Nhóm

Nhóm 11 — Viện Trí tuệ Nhân tạo, Trường Đại học Công nghệ, DHQGHN

STT	MSSV	Họ và tên	Công việc đảm nhiệm
1	24022404	Nguyễn Đức Minh	Huấn luyện XLM-RoBERTa song ngữ (notebook 02) và Hybrid RoBERTa + PhoBERT (notebook 03): fine-tune với R-Drop, routing logic, đánh giá test set, upload model.
2	23021661	Nguyễn Hoàng Phúc	Tải dữ liệu và tiền xử lý (notebook 01): download FAIDSet, MAGE, xây dựng pipeline ELT + augmentation; đánh giá test set (notebook 04), phân tích feature quan trọng (notebook 05); viết báo cáo.

Phân công công việc trong nhóm. Cả hai thành viên cùng đóng góp vào thảo luận, review code và buổi trình bày.

Abstract

Sự bùng nổ của các Mô hình Ngôn ngữ Lớn (LLM) như GPT-4, Gemini và LLaMA đặt ra nhu cầu cấp thiết về khả năng phân biệt văn bản do con người viết và văn bản do AI tạo ra. Bài toán này có ứng dụng thực tiễn trong kiểm tra học thuật, kiểm duyệt nội dung và bảo đảm tính xác thực của thông tin.

Dự án này xây dựng hệ thống phân loại văn bản nhị phân (*Human-written / AI-generated*) trên dữ liệu song ngữ Anh–Việt, sử dụng hai chiến lược, cả hai đều được huấn luyện với kỹ thuật **R-Drop** để ổn định quá trình học: (1) fine-tune **XLM-RoBERTa** trên toàn bộ dữ liệu cùng lúc, và (2) mô hình **Hybrid** kết hợp ROBERTA (tiếng Anh) với PHOBERT (tiếng Việt) thông qua cơ chế routing ngôn ngữ tự động.

Tập dữ liệu gồm **FAIDSet** (ngocminhta/FAIDSet, song ngữ Anh–Việt) và **MAGE** (yaful/MAGE, tiếng Anh) — tổng cộng 48,257 mẫu huấn luyện (bao gồm 3,984 mẫu Human được tăng cường bằng back-translation) và 65,899 mẫu kiểm tra. Trên tập test, XLM-RoBERTa đạt macro F1 = 0.7913 tổng thể (F1 tiếng Việt = 0.9867, F1 tiếng Anh = 0.7799), trong khi mô hình Hybrid đạt macro F1 = 0.7740 (F1 tiếng Việt = 0.9880, F1 tiếng Anh = 0.7611) — XLM-RoBERTa nhích hơn Hybrid khoảng +0.017 F1 tổng thể, dù Hybrid sử dụng hai mô hình chuyên biệt theo ngôn ngữ. Cả hai mô hình đều chưa đạt mức khuyến nghị F1 ≥ 0.8 của đề bài. Phân tích kết quả chỉ ra rằng hiệu năng thấp trên tập tiếng Anh xuất phát chủ yếu từ *recall* rất thấp của lớp Human (≈ 0.58 – 0.64), khiến văn bản người viết dễ bị nhận lầm thành AI-generated.

Từ khóa: phát hiện văn bản AI, XLM-RoBERTa, PhoBERT, R-Drop, fine-tuning, phân loại văn bản, song ngữ Anh–Việt, FAIDSet, MAGE.

Contents

1	Giới thiệu	6
1.1	Bối cảnh và Động lực	6
1.2	Phát biểu Bài toán	6
1.3	Đề xuất Giải pháp	6
1.4	Đóng góp Chính	7
1.5	Cấu trúc Báo cáo	7
2	Dữ liệu	8
2.1	Nguồn Dữ liệu	8
2.2	Pipeline Tiền xử lý — ELTA	8
2.2.1	E — Extract (Trích xuất)	8
2.2.2	L — Load (Đọc dữ liệu)	8
2.2.3	T — Transform (Biến đổi)	8
2.2.4	A — Augmentation (Tăng cường dữ liệu)	8
2.3	Thống kê Dữ liệu	9
2.4	Lưu ý về Validation Set	9
3	Kiến trúc Mô hình	10
3.1	Mô hình 1 — XLM-RoBERTa Song ngữ	10
3.1.1	Lý do Lựa chọn	10
3.1.2	Kiến trúc	10
3.1.3	Chiến lược Class Weighting	10
3.2	R-Drop — Kỹ thuật Huấn luyện Chung	10
3.3	Mô hình 2 — Hybrid (RoBERTa + PhoBERT)	11
3.3.1	Lý do Lựa chọn Kiến trúc Hybrid	11
3.3.2	Routing Logic	11
3.3.3	Word Segmentation cho PhoBERT	11
3.4	Bảng So sánh Hai Mô hình	12
4	Huấn luyện	13
4.1	Siêu tham số	13
4.2	Vòng lặp Huấn luyện	13
4.3	Kết quả Huấn luyện	13
4.3.1	Mô hình 1 — XLM-RoBERTa	13
4.3.2	Mô hình 2 — Hybrid (RoBERTa + PhoBERT)	14
5	Đánh giá	15
5.1	Giao thức Đánh giá	15
5.2	Kết quả Tổng thể	15
5.3	Kết quả theo Ngôn ngữ	15
5.4	Phân phối Chiến lược Routing (Mô hình Hybrid)	16
6	Phân tích Kết quả	17
6.1	Tại sao Precision Cao nhưng F1 Thấp trên Tập EN?	17
6.2	Ước tính Confusion Matrix	17
6.3	Nguyên nhân — Khả năng Phân kỳ Phân phối (Distribution Shift)	17
6.4	Tại sao Tiếng Việt Đạt F1 Cao?	18

6.5	So sánh Hai Mô hình	18
6.6	Đối chiếu với Yêu cầu Đề bài	18
7	Phân tích Feature Quan trọng	19
7.1	Hướng 1 — Feature Thống kê	19
7.1.1	Kết quả	19
7.2	Hướng 2 — Attention Visualization	20
7.2.1	So sánh hai model trên các mẫu cụ thể	20
7.2.2	Top token được chú ý nhiều nhất	22
7.3	Tóm tắt	23
8	Kết luận	24
8.1	Tóm tắt	24
8.2	Hạn chế	24
8.3	Hướng Cải tiến	24
	Tài liệu Tham khảo	26

List of Figures

1	Boxplot ba feature thống kê theo nhóm Human (xanh) và AI (cam), tách riêng tiếng Anh (hàng trên) và tiếng Việt (hàng dưới). Đường đứt nét là giá trị trung bình. Cả ba chỉ số đều cho thấy $AI > Human$ nhưng hai phân phối overlap đáng kể, không đủ để phân loại đơn lẻ.	20
2	Attention visualization so sánh XLM-R (cột trái) và Hybrid (cột phải) trên 7 mẫu đại diện. Màu đỏ đậm = token được model chú ý nhiều nhất. Tiêu đề mỗi biểu đồ ghi nhãn thực tế, nhãn dự đoán và xác suất. . . .	21
3	Top 15 token được model chú ý nhiều nhất trên tập EN, tổng hợp từ 200 mẫu (100 Human, 100 AI). Hàng trên: XLM-R. Hàng dưới: Hybrid/RoBERTa. Cột xanh: nhóm Human. Cột cam: nhóm AI. . . .	22

List of Tables

1	Thống kê dữ liệu sau tiền xử lý và augmentation.	9
2	So sánh kiến trúc hai mô hình.	12
3	Siêu tham số huấn luyện cho cả hai mô hình.	13
4	Kết quả val F1 qua các epoch — XLM-RoBERTa + R-Drop.	13
5	Kết quả val F1 qua các epoch — RoBERTa (EN) + R-Drop.	14
6	Kết quả val F1 qua các epoch — PhoBERT (VI) + R-Drop.	14
7	Kết quả đánh giá trên tập test tổng (EN + VI, 65,899 mẫu).	15
8	Kết quả đánh giá trên tập test EN (62,621 mẫu).	15
9	Kết quả đánh giá trên tập test VI (3,278 mẫu).	16
10	Số mẫu theo từng nhánh routing — Mô hình Hybrid (tính trên toàn bộ tập test, 65,899 mẫu).	16
11	Ước tính confusion matrix — XLM-RoBERTa trên test EN.	17
12	Tóm tắt so sánh hiệu năng hai mô hình (test set).	18
13	Đối chiếu kết quả với yêu cầu $F1 \geq 0.8$ của đề bài.	18
14	Thống kê ba feature theo nhóm (Human/AI) và ngôn ngữ (EN/VI). . .	19
15	Tóm tắt kết quả phân tích feature.	23

1 Giới thiệu

1.1 Bối cảnh và Động lực

Sự phát triển mạnh mẽ của các Mô hình Ngôn ngữ Lớn (Large Language Models — LLM) trong những năm gần đây, tiêu biểu là ChatGPT, Gemini, Claude và LLaMA, đã làm thay đổi sâu sắc cách con người tạo ra và tiêu thụ văn bản. Các mô hình này có khả năng tạo ra những đoạn văn trôi chảy, mạch lạc và thuyết phục ở quy mô lớn, gây ra những thách thức nghiêm trọng trong việc xác thực tính xác thực của nội dung [1].

Bài toán phát hiện văn bản do AI sinh ra (*AI-generated text detection*) do đó trở nên cấp thiết trong nhiều lĩnh vực:

- **Giáo dục:** phát hiện gian lận học thuật khi sinh viên nộp bài luận được tạo bởi ChatGPT hoặc các công cụ tương tự.
- **Truyền thông:** kiểm duyệt tin giả (*fake news*) và nội dung thao túng dư luận được tạo hàng loạt bằng LLM.
- **Pháp lý:** xác thực tính xác thực của văn bản trong các quy trình tư pháp và hành chính.

Đặc biệt, bài toán trở nên phức tạp hơn trong bối cảnh **đa ngôn ngữ**: phần lớn nghiên cứu tập trung vào tiếng Anh, trong khi các ngôn ngữ ít tài nguyên hơn như tiếng Việt còn thiếu dữ liệu và công cụ phù hợp.

1.2 Phát biểu Bài toán

Bài toán: Cho một đoạn văn bản t (tiếng Anh hoặc tiếng Việt), xây dựng mô hình phân loại $f : t \mapsto \{0, 1\}$ sao cho $f(t) = 0$ nếu t là văn bản do con người viết (*Human-written*) và $f(t) = 1$ nếu t là văn bản do LLM tạo ra (*AI-generated*).

Hai thách thức chính nổi lên từ bài toán này:

- T1. Đa dạng nguồn sinh (*multi-source*).** Văn bản AI đến từ nhiều LLM khác nhau (GPT-3.5, GPT-4, LLaMA, Falcon, Mistral, v.v.), mỗi mô hình có phong cách viết và điểm đặc trưng riêng, khiến mô hình phân loại phải tổng quát tốt trên nhiều phân phối dữ liệu.
- T2. Đa ngôn ngữ.** Tiếng Việt là ngôn ngữ có đặc thù hình thái học (dùng dấu thanh, cấu trúc từ ghép) khác biệt hoàn toàn so với tiếng Anh. Mô hình phân loại cần xử lý hiệu quả cả hai ngôn ngữ cùng lúc.

1.3 Đề xuất Giải pháp

Dự án đề xuất hai chiến lược bổ trợ nhau, cả hai đều được huấn luyện bằng kỹ thuật **R-Drop** [4] (chi tiết Mục 3.2):

Chiến lược 1. XLM-RoBERTa Song ngữ. Fine-tune mô hình `xlm-roberta-base` [2] trên toàn bộ dữ liệu Anh + Việt cùng lúc. Ưu điểm: đơn giản, dễ triển khai, một mô hình duy nhất.

Chiến lược 2. Hybrid RoBERTa + PhoBERT. Huấn luyện riêng biệt ROBERTA

[5] cho tiếng Anh và PHOBERT [7] cho tiếng Việt, sau đó kết hợp thông qua cơ chế routing tự động dựa trên phát hiện ngôn ngữ (*language detection*). Ưu điểm: mỗi mô hình được tối ưu hóa riêng cho ngôn ngữ của mình.

1.4 Đóng góp Chính

Các đóng góp chính của dự án bao gồm:

- Xây dựng **pipeline tiền xử lý dữ liệu** kết hợp FAIDSet và MAGE, tạo ra tập dữ liệu song ngữ quy mô lớn với 48,257 mẫu huấn luyện, bao gồm tăng cường dữ liệu bằng **back-translation** cho lớp Human.
- Huấn luyện và đánh giá **hai kiến trúc mô hình**, cả hai dùng kỹ thuật **R-Drop**, với kết quả có thể so sánh trực tiếp trên cùng tập kiểm tra.
- Phân tích chi tiết **nguyên nhân hạn chế hiệu năng** trên tiếng Anh, chủ yếu do recall thấp của lớp Human.
- Đạt **F1 ≥ 0.98** trên tiếng Việt ở cả hai mô hình, vượt khuyến nghị F1 ≥ 0.8 của đề bài.

1.5 Cấu trúc Báo cáo

Phần còn lại của báo cáo được tổ chức như sau: Mục 2 mô tả bộ dữ liệu và quy trình tiền xử lý. Mục 3 trình bày kiến trúc hai mô hình. Mục 4 mô tả quá trình huấn luyện. Mục 5 báo cáo kết quả định lượng. Mục 6 phân tích nguyên nhân hạn chế. Mục 7 phân tích đặc trưng ngôn ngữ và attention. Mục 8 kết luận và đề xuất hướng cải tiến.

2 Dữ liệu

2.1 Nguồn Dữ liệu

Dự án sử dụng hai bộ dữ liệu công khai:

FAIDSet (ngocminhta/FAIDSet) [6] là bộ dữ liệu song ngữ Anh–Việt gồm ba nhãn: *human-written*, *llm-generated*, và *collaborative* (con người chỉnh sửa văn bản AI). Dự án chỉ giữ lại hai nhãn đầu; nhãn *collaborative* bị loại bỏ (45,846 record bị loại trên tổng ba split, cộng thêm 23 record bị loại do ngôn ngữ phát hiện không phải EN/VI). Dữ liệu được cung cấp sẵn theo split **train/valid/test**.

MAGE (yafu/MAGE) [3] là bộ dữ liệu tiếng Anh quy mô lớn, tổng hợp văn bản từ nhiều LLM khác nhau và nhiều domain (tin tức, học thuật, mạng xã hội, trả lời câu hỏi). Quy ước nhãn của MAGE (**label=1**: human, **label=0**: machine-generated trong dữ liệu gốc) được đảo chiều để thống nhất với FAIDSet (**label=0**: human, **label=1**: AI).

2.2 Pipeline Tiền xử lý — ELTA

Quá trình tiền xử lý được tổ chức theo mô hình ELT, mở rộng thêm bước **Augmentation (A)** bằng back-translation:

2.2.1 E — Extract (Trích xuất)

- **Train EN**: FAIDSet train EN + FAIDSet valid EN + 15,000 mẫu MAGE train (7,500 human + 7,500 AI, **random_state=42**).
- **Train VI**: FAIDSet train VI + FAIDSet valid VI.
- **Test EN**: FAIDSet test EN + toàn bộ MAGE test (60,279 mẫu sau lọc ≥ 50 ký tự).
- **Test VI**: FAIDSet test VI.

2.2.2 L — Load (Đọc dữ liệu)

Toàn bộ file **.txt** được đọc vào DataFrame với các cột: **text**, **label** (0 = human, 1 = AI), **language** (en/vi).

2.2.3 T — Transform (Biến đổi)

- Làm sạch văn bản: chuẩn hóa khoảng trắng, loại bỏ ký tự thừa.
- Lọc mẫu quá ngắn: giữ lại các mẫu ≥ 50 ký tự.
- Trích 10% **train_all** (49,193 mẫu sau clean+filter) làm **validation set nội bộ**, stratify theo cặp (**language**, **label**).

2.2.4 A — Augmentation (Tăng cường dữ liệu)

Sau khi **train.csv** (44,273 mẫu, phần 90% còn lại sau khi tách val) đã được clean và filter, dự án áp dụng **back-translation** để tăng cường riêng cho lớp *Human*:

- **Tiếng Anh**: dịch EN $\rightarrow$ FR $\rightarrow$ EN bằng Helsinki-NLP/opus-mt-en-fr và opus-mt-fr-en.
- **Tiếng Việt**: dịch VI $\rightarrow$ EN $\rightarrow$ VI bằng Helsinki-NLP/opus-mt-vi-en và opus-mt-en-vi.

- Lấy mẫu ngẫu nhiên 2,000 mẫu Human mỗi ngôn ngữ (`random_state=42`) để augment, dùng beam search (`num_beams = 4`, `max_new_tokens = 256`).
- Văn bản sau back-translation được đưa qua **đúng cùng hàm `clean_and_filter`** như dữ liệu gốc, đảm bảo tính đồng nhất trước khi gộp vào `train.csv`.

Kết quả: 1,998/2,000 mẫu EN và 1,986/2,000 mẫu VI vượt qua filter sau augmentation (một số mẫu bị loại vì quá ngắn sau khi dịch hai lần), bổ sung tổng cộng **3,984 mẫu Human** vào tập train.

2.3 Thống kê Dữ liệu

Bảng 1 tóm tắt số lượng mẫu sau tiền xử lý và augmentation. Tập train tăng từ 44,273 lên **48,257 mẫu** (+3,984 mẫu Human từ back-translation); tập validation, test EN và test VI không thay đổi.

Table 1. Thống kê dữ liệu sau tiền xử lý và augmentation.

Tập	Tổng	EN Human	EN AI	VI Human	VI AI
Train (gốc + augmented)	48,257	14,227	14,989	11,984	7,057
<i>trong đó augmented</i>	<i>3,984</i>	<i>1,998</i>	<i>0</i>	<i>1,986</i>	<i>0</i>
Validation	4,920	1,359	1,666	1,111	784
Test EN	62,621	30,899	31,722	—	—
Test VI	3,278	—	—	1,958	1,320
Test tổng	65,899	62,621		3,278	

Sau augmentation, tỉ lệ Human/AI trong train EN cải thiện từ $\approx 45\% : 55\%$ lên $\approx 49\% : 51\%$ — gần cân bằng hơn, kỳ vọng giúp tăng recall của lớp Human khi suy luận trên test EN (dù kết quả thực tế ở Mục 5 cho thấy recall Human trên test EN vẫn ở mức thấp, 0.58–0.64).

2.4 Lưu ý về Validation Set

Cần lưu ý rằng một phần mẫu MAGE train bị lẫn vào `val.csv` do thực hiện split *trước* bước augmentation (`val.csv` được tách ra từ `train_all` ngay sau Transform, trước khi back-translation được áp dụng riêng cho phần còn lại của train). Điều này không phải data leakage nghiêm trọng vì MAGE train và MAGE test là hai split hoàn toàn tách biệt, tuy nhiên `val.csv` **không** chứa mẫu augmented (vì augmentation chỉ áp dụng cho `train.csv` sau khi đã tách val), nên phân phối val không hoàn toàn giống phân phối train cuối cùng.

3 Kiến trúc Mô hình

3.1 Mô hình 1 — XLM-RoBERTa Song ngữ

3.1.1 Lý do Lựa chọn

XLM-RoBERTa [2] là mô hình Transformer đa ngôn ngữ được pre-train trên 100 ngôn ngữ, bao gồm cả tiếng Việt và tiếng Anh, sử dụng tokenizer SentencePiece chung cho tất cả ngôn ngữ. Điều này cho phép một mô hình duy nhất xử lý cả hai ngôn ngữ mà không cần tokenizer riêng.

3.1.2 Kiến trúc

Pipeline xử lý của XLM-RoBERTa gồm 6 bước nối tiếp (Hình ??): Input Text $\rightarrow$ Tokenizer (SentencePiece, `max_length=128`) $\rightarrow$ Embedding Layer (768 chiều) $\rightarrow$ Transformer Encoder (12 lớp) $\rightarrow$ biểu diễn token [CLS] (tổng hợp ngữ nghĩa toàn câu) $\rightarrow$ Linear Classifier (768 $\rightarrow$ 2) + Softmax, cho ra $P(\text{Human-written})$ và $P(\text{AI-generated})$.

- **Backbone:** `xlm-roberta-base` (12 transformer layers, hidden size 768).
- **Classification head:** Linear layer 768 $\rightarrow$ 2 (binary classification: human vs. AI), được khởi tạo mới (không có trong checkpoint pre-trained).
- **Input:** chuỗi văn bản, tối đa `MAX_LEN = 128` token.

3.1.3 Chiến lược Class Weighting

Do tập EN mất cân bằng nhẹ (AI nhiều hơn Human), mô hình sử dụng `CrossEntropyLoss` với class weight được tính bằng `sklearn.compute_class_weight('balanced')` trên tập EN:

$$w_c = \frac{N}{C \cdot N_c} \quad (1)$$

với N là tổng số mẫu EN, $C = 2$ là số lớp, và N_c là số mẫu lớp c . Kết quả: $w_{\text{human}} = 1.0268$, $w_{\text{AI}} = 0.9746$.

3.2 R-Drop — Kỹ thuật Huấn luyện Chung

Cả hai mô hình (XLM-RoBERTa và Hybrid) được huấn luyện với kỹ thuật **R-Drop** (Regularized Dropout) [4], một cải tiến so với fine-tuning thông thường nhằm tăng độ ổn định của mô hình. Ý tưởng cốt lõi: trong mỗi bước huấn luyện, mỗi batch được **forward hai lần qua cùng một mô hình** (với hai mặt nạ dropout khác nhau do tính ngẫu nhiên của dropout), tạo ra hai phân phối logits p_1, p_2 . Hàm loss tổng được tính bằng:

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \alpha \cdot \mathcal{L}_{\text{KL}} \quad (2)$$

trong đó $\mathcal{L}_{\text{CE}}$ là trung bình cross-entropy loss của hai lần forward, $\alpha = 0.5$, và $\mathcal{L}_{\text{KL}}$ là KL-divergence hai chiều (*bidirectional*) giữa p_1 và p_2 :

$$\mathcal{L}_{\text{KL}} = \frac{1}{2} \left(D_{\text{KL}}(p_1 \parallel p_2) + D_{\text{KL}}(p_2 \parallel p_1) \right) \quad (3)$$

Thành phần $\mathcal{L}_{\text{KL}}$ ép hai lần dự đoán (dưới hai mặt nạ dropout khác nhau) phải cho kết quả gần giống nhau, giúp mô hình ổn định hơn và giảm phương sai khi inference (lúc đó dropout bị tắt, chỉ có một lần forward). Lưu ý rằng R-Drop chỉ thay đổi cách tính loss khi **huấn luyện**; kiến trúc mô hình và quy trình suy luận (*inference*) không thay đổi so với fine-tuning thông thường.

3.3 Mô hình 2 — Hybrid (RoBERTa + PhoBERT)

3.3.1 Lý do Lựa chọn Kiến trúc Hybrid

Thay vì dùng một mô hình đa ngôn ngữ tổng quát, chiến lược Hybrid khai thác ưu điểm của từng mô hình chuyên biệt: ROBERTA [5] được pre-train chuyên sâu trên tiếng Anh, trong khi PHOBERT [7] được pre-train trên kho ngữ liệu tiếng Việt từ Wikipedia và báo điện tử. Cả hai backbone (`roberta-base` và `vinai/phobert-base-v2`) đều được huấn luyện độc lập với R-Drop (Mục 3.2), sau đó kết hợp lại thông qua cơ chế routing.

3.3.2 Routing Logic

Cơ chế routing tự động chọn mô hình dựa trên kết quả phát hiện ngôn ngữ (thư viện `langdetect`, `DetectorFactory.seed = 42`):

$$\hat{y} = \begin{cases} f_{\text{RoBERTa}}(t) & \text{nếu lang}(t) = \text{en và } P(\text{lang}) \geq 0.8 \\ f_{\text{PhoBERT}}(t) & \text{nếu lang}(t) = \text{vi và } P(\text{lang}) \geq 0.8 \\ \frac{f_{\text{RoBERTa}}(t) + f_{\text{PhoBERT}}(t)}{2} & \text{trường hợp còn lại} \end{cases} \quad (4)$$

Ngưỡng $\theta = 0.8$ được chọn để đảm bảo routing cứng (*hard routing*) chỉ khi mô hình phát hiện ngôn ngữ đủ tự tin **và** ngôn ngữ phát hiện là EN hoặc VI. Các trường hợp còn lại — gồm cả khi độ tin cậy thấp ($P < 0.8$) **và** khi ngôn ngữ phát hiện được không phải EN/VI dù độ tin cậy cao — đều dùng *soft voting* (trung bình xác suất của cả hai mô hình).

3.3.3 Word Segmentation cho PhoBERT

PhoBERT yêu cầu văn bản tiếng Việt phải được **tách từ** trước khi tokenize, vì BPE tokenizer của PhoBERT được xây dựng dựa trên đơn vị từ (không phải ký tự đơn lẻ). Dự án sử dụng thư viện `underthesea`:

```

1 from underthesea import word_tokenize
2
3 def segment_vi(text):
4     return word_tokenize(text, format="text")
5
6 class TextDataset(Dataset):
7     def __getitem__(self, idx):
8         text = self.texts[idx]
9         if self.segment:                # True chỉ khi dùng PhoBERT

```

```

10         text = segment_vi(text)
11         enc = self.tok(text, ...)

```

Listing 1. Word segmentation on-the-fly trong DataLoader.

Segmentation được thực hiện *on-the-fly* trong `__getitem__` của DataLoader, không lưu lại file CSV, đảm bảo không ảnh hưởng đến pipeline của Mô hình 1.

3.4 Bảng So sánh Hai Mô hình

Table 2. So sánh kiến trúc hai mô hình.

Đặc điểm	Mô hình 1 (XLM-R)	Mô hình 2 (Hybrid)
Số mô hình	1 mô hình duy nhất	2 mô hình riêng biệt
Backbone EN	xlm-roberta-base	roberta-base
Backbone VI	xlm-roberta-base	vinai/phobert-base-v2
Tokenizer	SentencePiece (chung)	BPE riêng cho từng ngôn ngữ
VI Segmentation	Không cần	Bắt buộc (underthesea)
Kỹ thuật huấn luyện	R-Drop	R-Drop (cả hai backbone)
Inference	Batch (DataLoader)	Từng mẫu (routing logic)

4 Huấn luyện

4.1 Siêu tham số

Table 3. Siêu tham số huấn luyện cho cả hai mô hình.

Siêu tham số	Mô hình 1 (XLM-R)	Mô hình 2 (Hybrid)
Độ dài tối đa (MAX_LEN)	128 token	128 token
Batch size	32	32
Số epoch	3	3
Learning rate	2×10^{-5}	2×10^{-5}
Weight decay	0.01	0.01
Optimizer	AdamW	AdamW
Scheduler	Linear warmup (10%)	Linear warmup (10%)
Gradient clipping	1.0	1.0
R-Drop α	0.5	0.5
Ngưỡng routing	—	$\theta = 0.8$
Random seed	42	42

4.2 Vòng lặp Huấn luyện

Mỗi epoch bao gồm hai giai đoạn:

1. **Training phase:** duyệt toàn bộ `train_loader`, forward pass **hai lần** qua mô hình (R-Drop, Mục 3.2), tính loss tổng hợp, backward pass, cập nhật trọng số.
2. **Validation phase:** duyệt `val_loader` ở chế độ `eval()` (không cập nhật gradient, chỉ một lần forward), tính macro F1. Nếu val F1 cải thiện so với epoch trước, lưu checkpoint.

Lưu ý quan trọng: `val_loader` sử dụng `val.csv` (tập *validation nội bộ*), **không phải** `test_en.csv` hay `test_vi.csv`. Tập test chỉ được dùng ở bước đánh giá cuối cùng (Mục 5).

4.3 Kết quả Huấn luyện

4.3.1 Mô hình 1 — XLM-RoBERTa

Table 4. Kết quả val F1 qua các epoch — XLM-RoBERTa + R-Drop.

Epoch	Train Loss	Val F1 (macro)	Checkpoint
1	0.2666	0.9154	Lưu
2	0.1157	0.9310	Lưu (best)
3	0.0623	0.9229	—

Mô hình tốt nhất được lưu ở **epoch 2** với val F1 = 0.9310; epoch 3 có train loss thấp hơn nhưng val F1 giảm nhẹ, một dấu hiệu overfitting nhẹ vào cuối quá trình huấn luyện. Checkpoint epoch 2 được dùng cho toàn bộ đánh giá ở Mục 5.

4.3.2 Mô hình 2 — Hybrid (RoBERTa + PhoBERT)

RoBERTa (EN):

Table 5. Kết quả val F1 qua các epoch — RoBERTa (EN) + R-Drop.

Epoch	Train Loss	Val F1 (macro)	Checkpoint
1	0.3450	0.8429	Lưu
2	0.1441	0.8834	Lưu (best)
3	0.0732	0.8834	Lưu (bằng epoch 2)

PhoBERT (VI):

Table 6. Kết quả val F1 qua các epoch — PhoBERT (VI) + R-Drop.

Epoch	Train Loss	Val F1 (macro)	Checkpoint
1	0.1056	0.9698	Lưu
2	0.0141	0.9778	Lưu
3	0.0054	0.9892	Lưu (best)

Khác với RoBERTa (EN), PhoBERT (VI) cải thiện **liên tục** qua cả ba epoch và đạt val F1 cao nhất ở epoch cuối (0.9892) — không có dấu hiệu overfitting trong phạm vi 3 epoch đã huấn luyện, có thể do tập val VI (1,895 mẫu) khá đồng nhất với phân phối train VI.

Hybrid trên val set: Khi kết hợp hai mô hình con (RoBERTa + PhoBERT) qua cơ chế routing, Hybrid đạt val F1 (macro) = 0.9266 trên toàn bộ `val.csv` — thấp hơn cả hai mô hình con tính riêng lẻ trên đúng phân phối ngôn ngữ của mình, vì val set có cả mẫu EN và VI được trộn vào một phép đánh giá duy nhất.

5 Đánh giá

5.1 Giao thức Đánh giá

Đánh giá được thực hiện trên **tập TEST** (không được dùng trong quá trình huấn luyện), gồm:

- **test_en.csv**: 62,621 mẫu EN (FAIDSet test EN + toàn bộ MAGE test).
- **test_vi.csv**: 3,278 mẫu VI (FAIDSet test VI).
- **Tổng cộng: 65,899 mẫu.**

Các chỉ số được báo cáo: **Precision**, **Recall**, **F1-score** theo từng lớp (Human, AI) và **Macro F1** tổng thể và theo ngôn ngữ.

5.2 Kết quả Tổng thể

Table 7. Kết quả đánh giá trên tập test tổng (EN + VI, 65,899 mẫu).

Mô hình	Lớp	Precision	Recall	F1	Support
XLM-RoBERTa + R-Drop	Human	0.9062	0.6575	0.7621	32,857
	AI	0.7325	0.9323	0.8204	33,042
	<i>Accuracy</i>		<i>0.7953</i>		65,899
	Macro avg	0.8193	0.7949	0.7913	65,899
Hybrid + R-Drop	Human	0.9334	0.6044	0.7337	32,857
	AI	0.7087	0.9571	0.8144	33,042
	<i>Accuracy</i>		<i>0.7812</i>		65,899
	Macro avg	0.8210	0.7807	0.7740	65,899

XLM-RoBERTa nhích hơn Hybrid khoảng +0.017 macro F1 trên tập test tổng, mặc dù Hybrid sử dụng hai mô hình được chuyên biệt hóa theo từng ngôn ngữ. Điểm này sẽ được phân tích sâu hơn ở Mục 6.

5.3 Kết quả theo Ngôn ngữ

Table 8. Kết quả đánh giá trên tập test EN (62,621 mẫu).

Mô hình	Lớp	Precision	Recall	F1	Support
XLM-RoBERTa + R-Drop	Human	0.8981	0.6371	0.7454	30,899
	AI	0.7245	0.9296	0.8143	31,722
	Macro avg	0.8113	0.7834	0.7799	62,621
Hybrid + R-Drop	Human	0.9268	0.5805	0.7139	30,899
	AI	0.7004	0.9553	0.8083	31,722
	Macro avg	0.8136	0.7679	0.7611	62,621

Table 9. Kết quả đánh giá trên tập test VI (3,278 mẫu).

Mô hình	Lớp	Precision	Recall	F1	Support
XLM-RoBERTa + R-Drop	Human	0.9990	0.9796	0.9892	1,958
	AI	0.9705	0.9985	0.9843	1,320
	Macro avg	0.9848	0.9890	0.9867	3,278
Hybrid + R-Drop	Human	0.9995	0.9811	0.9902	1,958
	AI	0.9727	0.9992	0.9858	1,320
	Macro avg	0.9861	0.9902	0.9880	3,278

5.4 Phân phối Chiến lược Routing (Mô hình Hybrid)

Table 10. Số mẫu theo từng nhánh routing — Mô hình Hybrid (tính trên toàn bộ tập test, 65,899 mẫu).

Strategy	Số mẫu	Tỉ lệ (%)
hard-roberta	62,588	94.98
hard-phobert	3,278	4.97
soft-other	21	0.03
soft-bilingual	12	0.02
Tổng	65,899	100.00

Gần như toàn bộ mẫu (99.95%) được xử lý bởi nhánh hard routing, cho thấy `langdetect` phát hiện ngôn ngữ rất tin cậy trên dữ liệu này. Chỉ 33 mẫu (0.05%) cần soft voting.

6 Phân tích Kết quả

6.1 Tại sao Precision Cao nhưng F1 Thấp trên Tập EN?

Nhìn vào kết quả tiếng Anh (Bảng 8), ta thấy một pattern bất thường: Precision của lớp Human khá cao (0.90–0.93) nhưng F1 lại thấp hơn nhiều (0.71–0.75). Nguyên nhân nằm ở Recall thấp của lớp Human (0.58–0.64).

Diễn giải (ví dụ với XLM-RoBERTa): F1 là trung bình điều hòa của Precision và Recall:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \times 0.8981 \times 0.6371}{0.8981 + 0.6371} \approx 0.7454 \quad (5)$$

Mặc dù Precision = 0.8981 (khi mô hình nói “đây là văn bản người viết” thì đúng gần 90%), nhưng Recall = 0.6371 nghĩa là mô hình **bỏ sót hơn một phần ba** văn bản người thật — chúng bị phân loại nhầm thành AI.

6.2 Ước tính Confusion Matrix

Dựa trên Precision, Recall và support đã báo cáo, có thể ước tính confusion matrix cho XLM-RoBERTa trên tập test EN:

Table 11. Ước tính confusion matrix — XLM-RoBERTa trên test EN.

	Predicted Human	Predicted AI
Actual Human (30,899)	≈19,686 (TP)	≈11,213 (FN)
Actual AI (31,722)	≈2,233 (FP)	≈29,489 (TN)

Mô hình predict AI khoảng 40,702 lần so với chỉ 21,919 lần predict Human — thiên lệch rõ rệt về phía dự đoán AI, dù mức độ thiên lệch nhẹ hơn nhiều so với một mô hình baseline không augment (xem Mục 2 về lý do augment lớp Human).

6.3 Nguyên nhân — Khả năng Phân kỳ Phân phối (Distribution Shift)

Một nguyên nhân khả dĩ cho recall thấp của lớp Human trên test EN là **sự khác biệt phân phối** giữa nguồn train và nguồn test:

- **Train EN:** 29,216 mẫu (sau augmentation), kết hợp FAIDSet (học thuật) + 15k mẫu MAGE train + 1,998 mẫu back-translation.
- **Test EN:** 62,621 mẫu, trong đó phần lớn (khoảng 96%, ≈60,279/62,621) đến từ MAGE test — đa domain (mạng xã hội, hỏi đáp, creative writing), đa LLM.

Vì phần lớn dữ liệu train EN cũng đến từ FAIDSet và một phần MAGE train, nhưng tỉ trọng MAGE trong test EN cao hơn nhiều so với tỉ trọng MAGE trong train EN, mô hình có thể chưa thấy đủ đa dạng phong cách viết Human ở các domain mà MAGE test tập trung, khiến một bộ phận văn bản Human trong MAGE test bị gán nhầm thành AI. Đây là một giả thuyết hợp lý dựa trên cấu trúc dữ liệu, dù báo cáo này chưa đo trực tiếp được mức độ phân kỳ phân phối bằng một chỉ số định lượng cụ thể.

6.4 Tại sao Tiếng Việt Đạt F1 Cao?

Ngược lại với tiếng Anh, tiếng Việt đạt F1 (macro) $\approx 0.987\text{--}0.988$ ở cả hai mô hình, vì:

- **Phân phối đồng nhất hơn:** Cả train VI và test VI đều đến từ FAIDSet, không có nguồn dữ liệu thứ hai (tương đương MAGE) được trộn vào tập test VI.
- **PhoBERT được huấn luyện riêng** cho tiếng Việt với word segmentation phù hợp (Mục 3), và val F1 của riêng PhoBERT đạt 0.9892 ở epoch cuối.

6.5 So sánh Hai Mô hình

Khác với kỳ vọng ban đầu rằng mô hình chuyên biệt theo ngôn ngữ (Hybrid) sẽ vượt trội mô hình song ngữ đơn (XLM-RoBERTa), **kết quả thực tế cho thấy điều ngược lại:** XLM-RoBERTa đạt macro F1 tổng cao hơn Hybrid khoảng +0.017 (Bảng 12), và cũng cao hơn ở cả hai ngôn ngữ riêng lẻ. Một khả năng giải thích là RoBERTa (thành phần EN của Hybrid) chỉ được huấn luyện trên đúng tập train EN (29,216 mẫu, val F1 tốt nhất 0.8834), trong khi XLM-RoBERTa học chung trên cả EN và VI (48,257 mẫu) có thể đã hưởng lợi từ việc học các đặc trưng chia sẻ giữa hai ngôn ngữ. Cả hai mô hình đều cho recall Human trên test EN ở mức thấp tương đương nhau (0.5805–0.6371), gợi ý rằng vấn đề chính nằm ở **đặc điểm của dữ liệu test EN** hơn là sự khác biệt giữa hai kiến trúc.

Table 12. Tóm tắt so sánh hiệu năng hai mô hình (test set).

Mô hình	Macro F1 Tổng	F1 EN	F1 VI	Recall Human (EN)
XLM-RoBERTa + R-Drop	0.7913	0.7799	0.9867	0.6371
Hybrid + R-Drop	0.7740	0.7611	0.9880	0.5805

6.6 Đối chiếu với Yêu cầu Đề bài

Table 13. Đối chiếu kết quả với yêu cầu F1 ≥ 0.8 của đề bài.

Tiêu chí	Kết quả	Đạt yêu cầu?
Macro F1 ≥ 0.8 (tổng)	0.7740–0.7913	Chưa đạt
Macro F1 (lớp AI, EN)	0.8083–0.8143	Đạt
Macro F1 (tiếng Việt)	0.9867–0.9880	Vượt xa
Báo cáo Precision/Recall/F1	Đầy đủ	Đạt
Phân tích feature quan trọng	Có (Mục 7)	Đạt
Sử dụng RoBERTa / PhoBERT	Cả hai	Đạt

7 Phân tích Feature Quan trọng

Phần này trả lời hai câu hỏi bổ trợ nhau:

- **Hướng 1:** Văn bản Human và AI khác nhau về mặt ngôn ngữ như thế nào?
- **Hướng 2:** Model dựa vào đâu để đưa ra quyết định phân loại?

7.1 Hướng 1 — Feature Thống kê

Ba chỉ số thống kê được tính trực tiếp trên văn bản, không qua model, để quan sát sự khác biệt ngôn ngữ giữa hai nhóm:

Entropy đo độ đa dạng từ vựng, tính theo công thức Shannon:

$$H = - \sum_w p(w) \log_2 p(w) \quad (6)$$

Entropy cao nghĩa là văn bản dùng từ phong phú và đều đặn hơn.

Burstiness đo mức độ lặp từ theo cụm:

$$B = \frac{\sigma - \mu}{\sigma + \mu} \quad (7)$$

với μ và σ là trung bình và độ lệch chuẩn của khoảng cách giữa các lần xuất hiện của từng từ. B gần 1 nghĩa là từ xuất hiện theo cụm (bùng phát); B gần -1 nghĩa là phân phối đều. Do ngôn ngữ tự nhiên có nhiều từ chức năng lặp lại theo quy luật, giá trị B quan sát được ở cả Human và AI trong dự án này đều âm.

Độ dài câu trung bình tính bằng số từ trên mỗi câu, câu được tách theo dấu . ! ? .

7.1.1 Kết quả

Bảng 14 trình bày giá trị mean của ba chỉ số trên 3,000 mẫu EN và 2,820 mẫu VI được lấy cân bằng (50% Human, 50% AI).

Table 14. Thống kê ba feature theo nhóm (Human/AI) và ngôn ngữ (EN/VI).

Ngôn ngữ	Nhóm	Entropy	Burstiness	Avg sent length
EN	Human	5.9465	-0.1160	16.94
	AI	6.1081	-0.1142	18.98
VI	Human	5.5732	-0.2468	30.55
	AI	6.5784	-0.1727	33.48

Cả ba chỉ số đều cho kết quả nhất quán **AI** > **Human** ở cả hai ngôn ngữ: AI viết đa dạng từ vựng hơn (entropy cao hơn), phân phối từ đều hơn (burstiness cao hơn, tức ít âm hơn, gần 0 hơn), và câu dài hơn. Sự chênh lệch entropy rõ nhất ở tiếng Việt (AI cao hơn Human khoảng 1.0 đơn vị), trong khi tiếng Anh chỉ chênh khoảng 0.16 đơn vị.




Figure 1. Boxplot ba feature thống kê theo nhóm Human (xanh) và AI (cam), tách riêng tiếng Anh (hàng trên) và tiếng Việt (hàng dưới). Đường đứt nét là giá trị trung bình. Cả ba chỉ số đều cho thấy AI > Human nhưng hai phân phối overlap đáng kể, không đủ để phân loại đơn lẻ.

Tuy nhiên, phân phối của hai nhóm overlap khá nhiều (đặc biệt tiếng Anh), cho thấy ba feature này **không đủ để phân loại độc lập** — chúng chỉ phản ánh xu hướng trung bình, không phân biệt được từng mẫu cụ thể.

7.2 Hướng 2 — Attention Visualization


Để hiểu model dựa vào *token* nào để ra quyết định, attention weights từ layer cuối của mỗi model được trích xuất. Cụ thể, với mỗi văn bản đầu vào, attention của token [CLS] (token tổng hợp thông tin toàn câu) đến tất cả token còn lại được lấy từ layer cuối, trung bình qua tất cả attention heads:

$$\text{score}(t) = \frac{1}{H} \sum_{h=1}^H \alpha_{\text{CLS},t}^{(h)} \quad (8)$$

với H là số heads và $\alpha_{\text{CLS},t}^{(h)}$ là attention của [CLS] đến token t ở head h .

7.2.1 So sánh hai model trên các mẫu cụ thể

Figure 2 trình bày attention visualization cho 7 mẫu đại diện (5 EN + 2 VI), mỗi mẫu hiển thị XLM-R (cột trái) và Hybrid (cột phải) cạnh nhau.



Trong số các mẫu được kiểm tra, có trường hợp cả hai mô hình cùng dự đoán sai trên một văn bản Human tiếng Anh (gán nhầm thành AI với xác suất cao ở cả XLM-R và Hybrid/RoBERTa), minh họa trực tiếp cho vấn đề recall Human thấp đã thảo luận ở Mục 6.

7.2.2 Top token được chú ý nhiều nhất

Figure 3 tổng hợp top 15 token xuất hiện nhiều nhất trong top-attention của 200 mẫu EN, tách theo nhóm Human/AI cho cả hai model.




Figure 3. Top 15 token được model chú ý nhiều nhất trên tập EN, tổng hợp từ 200 mẫu (100 Human, 100 AI). Hàng trên: XLM-R. Hàng dưới: Hybrid/RoBERTa. Cột xanh: nhóm Human. Cột cam: nhóm AI.

Khác với kỳ vọng ban đầu rằng model sẽ chú ý vào các từ mang nội dung cụ thể (danh từ, động từ đặc trưng), kết quả thực tế cho thấy **cả hai model đều chú ý nhiều nhất vào dấu câu và từ chức năng** (dấu chấm, dấu phẩy, dấu nháy, dấu ngoặc, các từ như “the”), ở cả nhóm Human và AI. Token mang nội dung cụ thể (ví dụ “spaghetti”, “because”) chỉ xuất hiện ở thứ hạng thấp hơn trong top-15 và thường gắn với nhóm AI nhiều hơn Human.

Điều này gợi ý rằng cả hai model phân biệt Human/AI **không chủ yếu dựa vào loại từ được chú ý** (vì cả hai nhóm đều có top-token là dấu câu/từ chức năng tương tự nhau), mà nhiều khả năng dựa vào **mức độ lặp lại đều đặn** của các mẫu hình này — nhất quán với phát hiện ở Mục 7.1 rằng AI có burstiness cao hơn (ít âm hơn, tức phân phối từ đều đặn hơn) so với Human.

7.3 Tóm tắt

Table 15. Tóm tắt kết quả phân tích feature.

Câu hỏi	Kết quả
Human vs AI khác nhau thế nào?	AI viết đa dạng từ vựng hơn, câu dài hơn, phân phối từ đều hơn (burstiness ít âm hơn). Rõ nhất ở tiếng Việt (entropy chênh ~ 1.0), ít rõ hơn ở tiếng Anh (~ 0.16).
Model dựa vào gì để phân loại?	Chủ yếu dựa vào dấu câu và từ chức năng (giống nhau ở cả Human và AI), không phải từ mang nội dung — gợi ý ranh giới phân loại nằm ở mức độ lặp khuôn mẫu, không phải loại từ được dùng.

8 Kết luận

8.1 Tóm tắt

Dự án đã xây dựng hệ thống phát hiện văn bản do AI sinh ra trên dữ liệu song ngữ Anh–Việt với các đóng góp chính:

1. **Pipeline tiền xử lý và tăng cường dữ liệu** kết hợp FAIDSet và MAGE, áp dụng back-translation cho lớp Human, tạo ra tập dữ liệu chuẩn hóa với 48,257 mẫu huấn luyện và 65,899 mẫu kiểm tra, được lưu trữ dưới dạng CSV chuẩn.
2. **Mô hình XLM-RoBERTa song ngữ**, huấn luyện với R-Drop và class weighting — một mô hình duy nhất xử lý cả tiếng Anh và tiếng Việt, đạt macro F1 = 0.7913 trên test set, là kết quả **tốt nhất** trong hai mô hình đã thử nghiệm.
3. **Mô hình Hybrid** kết hợp RoBERTa (EN) và PhoBERT (VI), cũng huấn luyện với R-Drop, với routing logic tự động, đạt macro F1 = 0.7740 — nhẹ hơn XLM-RoBERTa khoảng 0.017, dù có F1 tiếng Việt cao nhất (0.9880).
4. **Phân tích nguyên nhân** hạn chế hiệu năng: recall thấp của lớp Human trên test EN (0.58–0.64) là nguyên nhân chính kéo macro F1 tổng xuống dưới ngưỡng khuyến nghị, khả năng liên quan đến sự khác biệt phân phối giữa nguồn train (chủ yếu FAIDSet) và nguồn test (chủ yếu MAGE, đa domain).

8.2 Hạn chế

- Macro F1 tổng (0.7740–0.7913) **chưa đạt** mức khuyến nghị $F1 \geq 0.8$ của đề bài, chủ yếu do recall thấp của lớp Human trên tập test EN.
- Mô hình chuyên biệt theo ngôn ngữ (Hybrid) **không vượt được** mô hình song ngữ đơn (XLM-RoBERTa) như kỳ vọng ban đầu — chuyên biệt hóa kiến trúc chưa mang lại lợi ích rõ ràng trong thử nghiệm này.
- Mô hình Hybrid inference từng mẫu một (không batch) nên có khả năng chậm hơn XLM-RoBERTa khi suy luận trên quy mô lớn.
- Khoảng cách giữa val F1 tốt nhất trong huấn luyện (0.88–0.93) và test F1 (0.77–0.79) cho thấy tập val nội bộ chưa đại diện hoàn toàn cho phân phối của tập test thật, đặc biệt với phần dữ liệu MAGE chiếm đa số trong test EN.
- Phân tích attention (Mục 7) cho thấy model dựa nhiều vào dấu câu và từ chức năng, chưa rõ ràng đã khai thác được tín hiệu ngữ nghĩa sâu hơn của nội dung văn bản.

8.3 Hướng Cải tiến

- **Tăng dữ liệu MAGE train đa domain:** Hiện tại train EN chỉ lấy 15,000 mẫu MAGE train (so với 60,279 mẫu MAGE test). Tăng số mẫu MAGE train và đảm bảo phủ nhiều domain hơn (mạng xã hội, hỏi đáp, sáng tác) có thể giúp giảm khoảng cách phân phối với test EN.
- **Điều chỉnh ngưỡng quyết định:** Vì recall Human đang thấp hơn nhiều so với recall AI, hạ ngưỡng phân loại từ 0.5 xuống một giá trị thấp hơn (cần tinh chỉnh trên val set) có thể giúp tăng recall Human mà không cần train lại mô hình.
- **Đo định lượng distribution shift:** Bổ sung các chỉ số định lượng (ví dụ so sánh

phân phối embedding hoặc thống kê ngôn ngữ giữa FAIDSet và MAGE) để xác nhận chắc chắn hơn giả thuyết về phân kỳ phân phối đã nêu ở Mục 6.

- **Khai thác attention sâu hơn:** Vì model hiện chủ yếu dựa vào dấu câu và từ chức năng, có thể thử các kỹ thuật khuyến khích model chú ý vào nội dung ngữ nghĩa hơn (ví dụ thêm đặc trưng burstiness/entropy như input bổ sung cho classifier).

Tài liệu Tham khảo

- [1] Tom Brown, Benjamin Mann, Nick Ryder, et al. “Language Models are Few-Shot Learners”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 1877–1901.
- [2] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, et al. “Unsupervised Cross-lingual Representation Learning at Scale”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (2020), pp. 8440–8451.
- [3] Yafu Li, Qintong Li, Leyang Cui, et al. “MAGE: Machine-generated Text Detection in the Wild”. In: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. 2024.
- [4] Xiaobo Liang, Lijun Wu, Juntao Li, et al. “R-Drop: Regularized Dropout for Neural Networks”. In: *Advances in Neural Information Processing Systems*. Vol. 34. 2021, pp. 10890–10905.
- [5] Yinhan Liu, Myle Ott, Naman Goyal, et al. “RoBERTa: A Robustly Optimized BERT Pretraining Approach”. In: *arXiv preprint arXiv:1907.11692* (2019).
- [6] ngocminhta. *FAIDSet: A Bilingual English-Vietnamese Dataset for AI-Generated Text Detection*. Hugging Face Datasets, <https://huggingface.co/datasets/ngocminhta/FAIDSet>. 2024.
- [7] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained language models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1037–1042.